

CODICI DI HUFFMAN

- CONSENTONO FATTORI DI COMPRESSIONE TRA IL 20% E IL 90%
- PROBLEMA: TROVARE UNA CODIFICA DI UN FILE DI CARATTERI IN MODO DA MINIMIZZARNE LA DIMENSIONE

ESEMPIO: FILE DI 100 CARATTERI

CAR.	FREQ.	COD 1 (8 BIT)	COD 2 (3 bit)	COD 3	
a	45 x 1	00000000	000	0	45
b	13 x 3	00000001	001	101	39
c	12 x 3	00000010	010	100	36
d	16 x 3	00000011	011	111	48
e	9 x 4	00000100	100	1101	36
f	5 x 4	00000101	101	1100	20
100		800 bit	300 bit	224 bit	

ES. abac

COD 2

000001000010

COD 3

01010100


LUNGHEZZA FISSA

LUNGH. VARIABILE

25% IN MEMO

$$300 : 100 = 76 : X$$

$$X = \frac{100 \cdot 76}{300} = 25,3\%$$



$$86 \times 3 + 14 \times 2 = 258 + 28$$

ALBERI DI DECODIFICA

CAR.	FREQ.	COD2 (3 bit)	COD3
a	45	000	0
b	13	001	101
c	12	010	100
d	16	011	111
e	9	100	1101
f	5	101	1100

ES.

a b a c

COD2

000 001 000 010


a b a c

COD3


0 1010100

a b a c

COD2



COD3




PIENO/FULL

- CODICI PREFISSI: SONO CODICI IN CUI NESSUNA CODIFICA E' PREFISSO DI UN'ALTRA CODIFICA

ESEMPIO DI CODICE NON PREFISSO NON AMBIGUO

a 0
b 01
c 11

0 1 1 1 1 1 1 1 1 1 1 1
b c c c a c



ESEMPIO DI CODICE NON PREFISSO AMBIGUO

a 0
b 1
c 01



?

$$f: C \rightarrow \mathbb{N}$$

ALBERI DI DECODIFICA

CAR.	FREQ.	COD2 (3 bit)	COD3
a	45 x 1	000	0
b	13 x 3	001	101
c	12 x 3	010	100
d	16 x 3	011	111
e	9 x 4	100	1101
f	5 x 4	101	1100

COMPLESSITA' DELLA CODIFICA:

$$B(\text{cod}) = \sum_{c \in C} f(c) | \text{cod}(c) |$$

$$= \sum_{c \in C} f(c) d_{T_{\text{cod}}}(c) \stackrel{\text{def}}{=} B(T_{\text{cod}})$$


T_{cod} : ALBERO DI DECODIFICA

C : ALFABETO


$$f: C \rightarrow \mathbb{N}$$

$d_{T_{\text{cod}}}$: PROFONDITA' IN T_{cod}

COD 2



COD 3



PROBLEMA: TRA TUTTI GLI ALBERI DI DECODIFICA
RELATIVI AD UN SISTEMA (C, f) (DOVE
 $f: C \rightarrow \mathbb{N}$) DETERMINARE QUELLO DI
COSTO MINIMO, CIOE' L'ALBERO
BINARIO DI DECODIFICA T TALE CHE

$$B(T) = \sum_{c \in C} f(c) d_T(c)$$


SIA MINIMO

OSSERVAZIONE: POSSIAMO LIMITARE LA NOSTRA RICERCA
AGLI ALBERI BINARI PIENI, QUELLI CIOE' PRIVI
DI NODI INTERNI CON UN SOLO FIGLIO.

OSSERVAZIONE: IL NUMERO DI NODI INTERNI
IN UN ALBERO BINARIO PIENO CON
 n FOGLIE E' $n-1$.

$$n = 1 \quad I = n - 1 = 1 - 1$$

$$n > 1$$




$$n_1 + n_2 = n$$


$$(n_1 - 1) + (n_2 - 1) + 1$$

$$= \underbrace{n_1 - 1} + \underbrace{n_2 - 1} + 1$$

$$= n - 1$$



- PER COSTRUIRE UN ALBERO BINARIO PIENO CON m NODI SI POSSONO EFFETTUARE $(m-1)$ OPERAZIONI DI MERGING



$$C_1 \cup C_2 = C$$

$$c \in C_1 \quad d_{T_1}(c) + 1 = d_T(c)$$

$$c \in C_2 \quad d_{T_2}(c) + 1 = d_T(c)$$

$$B(T) = \sum_{c \in C} f(c) \cdot d_T(c)$$


$$= \sum_{c \in C_1} f(c) \cdot d_T(c) + \sum_{c \in C_2} f(c) \cdot d_T(c)$$

$$= \sum_{c \in C_1} f(c) (d_{T_1}(c) + 1) + \sum_{c \in C_2} f(c) (d_{T_2}(c) + 1)$$

$$= \sum_{c \in C_1} f(c) d_{T_1}(c) + \sum_{c \in C_1} f(c)$$

$$+ \sum_{c \in C_2} f(c) d_{T_2}(c) + \sum_{c \in C_2} f(c)$$

$$= B(T_1) + B(T_2) + \sum_{c \in C} f(c)$$



$$C_1 \cup C_2 = C$$

$$c \in C_1 \quad d_{T_1}(c) + 1 = d_T(c)$$

$$c \in C_2 \quad d_{T_2}(c) + 1 = d_T(c)$$

$$B(T) = B(T_1) + B(T_2) + \sum_{c \in C} f(c)$$

$$\Delta B = B(T) - (B(T_1) + B(T_2))$$

$$= \sum_{c \in C} f(c) \quad \leftarrow \text{COSTO DELL'}$$

OPERAZIONE DI
MERGING DI
 T_1 E T_2




$$\begin{array}{r} 14 \\ 30 \\ 25 \\ 55 \\ \hline 100 \\ 224 \end{array}$$

PER INDUZIONE SULL'ALTEZZA DI T , SI DIMOSTRA CHE:

$B(T)$ = SOMMA DEI COSTI DI TUTTE LE OPERAZIONI
DI MERGING

CASO BASE: $\text{height}(T) = 1$ $B(T) = \text{merging}(\text{root}(T))$

PASSO INDUTTIVO:




$$B(T) = B(T_1) + B(T_2) + \sum_{c \in C} f(c)$$

$$= \sum_{v \in \text{int}(T_1)} \text{merging}(v) + \sum_{v \in \text{int}(T_2)} \text{merging}(v) + \text{merging}(\text{root}(T))$$

$$= \sum_{v \in \text{int}(T)} \text{merging}(v)$$

ESEMPIO:

1 0 0 1 0 1



14 +
30 +
25 +
55 +
100

224

- UNA POSSIBILE STRATEGIA "GREEDY" PER COSTRUIRE UN ALBERO DI COSTO MINIMO CONSISTE NELL'EFFETTUARE LE OPERAZIONI DI MERGING DI COSTO MINIMO

HUFFMAN(C, f)

$n := |C|$

$Q := \text{make_queue}(C, f)$

for $i := 1$ to $n-1$ do

- SI ALLOCA UN NUOVO NODO INTERNO z

$\text{left}[z] := x := \text{EXTRACT_MIN}(Q)$

$\text{right}[z] := y := \text{EXTRACT_MIN}(Q)$

$f[z] := f[x] + f[y]$

$\text{INSERT}(Q, z, f)$

return $\text{EXTRACT_MIN}(Q)$

COMPLESSITA'

$(2n-1)$ EXTRACTMIN $O(n \log n)$


$(n-1)$ INSERT $O(n \log n)$

BUILDHEAP $O(n)$

$O(n \log n)$

ESEMPIO


a:45




d:16




a:45



(3) d:16




a:45





d:16

e:9

f:5






$a = 0$
 $b = 100$
 $c = 101$
 $d = 110$
 $e = 1110$
 $f = 1111$

LOWER-BOUND SULLA COMPLESSITA': $\Omega(\lg n)$

$$\begin{cases} F(0) = 1 \\ F(1) = 1 \\ F(n) = F(n-1) + F(n-2) \end{cases}$$



a 00000
b 00001
c 0001
d 001
e 01
f 1

CORRETTEZZA DELL'ALGORITMO DI HUFFMAN

LEMMA

SIA C UN ALFABETO E $f: C \rightarrow \mathbb{N}$ UNA FUNZIONE FREQUENZA.

SIANO x ED y I DUE CARATTERI IN C DI FREQUENZA MINIMA.



ALLORA ESISTE UN CODICE OTTIMO PREFISSO PER C IN CUI LE CODIFICHE DI x ED y DIFFERISCONO SOLO PER L' ULTIMO BIT.

DIM. SIANO a E b DUE CARATTERI RESIDENTI SU FOGLIE
SORELLE DI PROFONDITA' MASSIMA IN UN ALBERO OTTIMO T .

SUPPONIAMO CHE $f(a) \leq f(b)$ E $f(x) \leq f(y)$.

ALLORA: $f(x) \leq f(a)$ E $f(y) \leq f(b)$,

SIA T' L'ALBERO OTTENUTO DA T SCAMBIANDO
I CARATTERI a ED x ,



SI HA:

$$\begin{aligned} B(T) - B(T') &= \sum_{c \in C} f(c) d_T(c) - \sum_{c \in C} f(c) d_{T'}(c) \\ &= f(a) d_T(a) + f(x) d_T(x) - f(a) d_{T'}(a) - f(x) d_{T'}(x) \\ &= f(a) d_T(a) + f(x) d_T(x) - f(a) d_T(x) - f(x) d_T(a) \\ &= f(a) (d_T(a) - d_T(x)) - f(x) (d_T(a) - d_T(x)) \\ &= (f(a) - f(x)) (d_T(a) - d_T(x)) \geq 0 \end{aligned}$$

POICHE' :

- $c \in C \setminus \{a, x\} \longrightarrow d_T(c) = d_{T'}(c)$
- $d_{T'}(a) = d_T(x)$
- $d_{T'}(x) = d_T(a)$

- SIA T'' L'ALBERO OTTENUTO DA T' SCAMBIANDO
I CARATTERI b ED y .

- ANALOGAMENTE A QUANTO VISTO PRIMA, SI HA:

$$B(T') - B(T'') \geq 0$$

- PERTANTO: $B(T) - B(T'') \geq 0$, DA CUI

$$B(T) \geq B(T'')$$

- POICHE' T E' OTTIMO, $B(T'') \geq B(T)$, E QUINDI

$B(T'')$ E' ANCH'ESSO OTTIMO

- INOLTRE IN T'' I CARATTERI x E y RISIEDONO SU
FOGLIE SORELLE E QUINDI I LORO CODICI DIFFERISCONO
SOLO PER L'ULTIMO BIT. ■

LEMMA

- SIA C UN ALFABETO E $f: C \rightarrow \mathbb{N}$ UNA FUNZIONE FREQUENZA.
 - SIANO x ED y I DUE CARATTERI IN C DI FREQUENZA MINIMA.
 - SIA $C' = (C \setminus \{x, y\}) \cup \{z\}$, CON $z \notin C$.
 - SIA $f': C' \rightarrow \mathbb{N}$ TALE CHE:
$$f'(c) = \begin{cases} f(c) & \text{SE } c \neq z \\ f(x) + f(y) & \text{SE } c = z \end{cases}$$
 - SIA T' UN ALBERO OTTIMO PER (C', f') .
 - SIA T L'ALBERO OTTENUTO DA T' SOSTITUENDO LA FOGLIA z CON UN NODO INTERNO AVENTE COME FIGLI DUE FOGLIE ETICHETTATE CON x ED y , RISPETTIVAMENTE.
- ALLORA T E' OTTIMO PER (C, f) .

SIN QUI 30/11/2021

DIM. SI HA:

$$B(T) = \sum_{c \in C} f(c) d_T(c) = \sum_{c \in C \setminus \{x, y\}} f(c) d_T(c) + f(x) d_T(x) + f(y) d_T(y)$$

$$= \sum_{c \in C \setminus \{x, y\}} f'(c) d_{T'}(c) + f(x)(d_{T'}(z)+1) + f(y)(d_{T'}(z)+1)$$

$$= \sum_{c \in C \setminus \{x, y\}} f'(c) d_{T'}(c) + f'(z) d_{T'}(z) + f(x) + f(y)$$

$$= \sum_{c \in C'} f'(c) d_{T'}(c) + f(x) + f(y)$$

$$= B(T') + f(x) + f(y)$$

DA CUI: $B(T') = B(T) - f(x) - f(y)$

- SE T NON FOSSE OTTIMO PER (C, f) , ESISTEREBBE UN ALBERO T'' OTTIMO PER (C, f) TALE CHE:
 $B(T'') < B(T)$.
- GRAZIE AL LEMMA PRECEDENTE, POSSIAMO SUPPORRE CHE x E y SI TROVINO SU FOGLIE SORELLE IN T'' .
- SIA T''' OTTENUTO DA T'' , SOSTITUENDO IL PADRE DI x E y CON UNA FOGLIA z CON FREQUENZA $f(x) + f(y)$.
- ALLORA:

$$\begin{aligned}
 B(T''') &= B(T'') - f(x) - f(y) \\
 &< B(T) - f(x) - f(y) \\
 &= B(T')
 \end{aligned}$$

CONTRADDICENDO L'OTTIMALITA' DI T' PER (C', f') .

- PERTANTO T E' OTTIMO PER (C, f) . ■